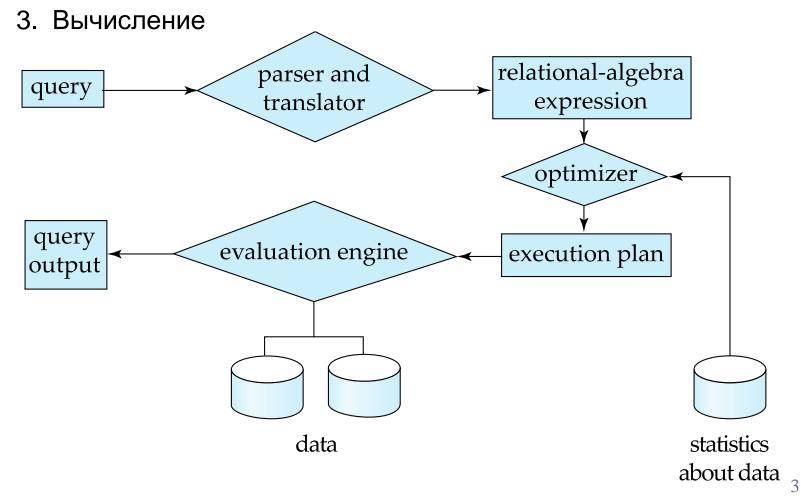
Обработка запросов

Обработка запросов

- Обзор
- Меры стоимости запросов
- Операция выборки
- Сортировка
- Операция соединения
- Другие операции
- Вычисления выражений

Основные шаги обработки запросов

- 1. Парсинг и трансляция
- 2. Оптимизация



Основные шаги обработки запросов

- Парсинг и трансляция
 - Осуществляется трансляция запроса в его внутреннюю форму. Затем осуществляется трансляция в реляционную алгебру.
 - Парсер осуществляет проверку синтаксиса и проверку отношений
- Вычисление
 - Механизм выполнения запросов принимает на вход план запросов, выполняет данный план, и возвращает ответ для запроса.

Основные шаги обработки запросов: Оптимизация

Выражения реляционной алгебры могу иметь эквивалентные выражения

```
select student_salary
from students
where student_salary < 75000
```

```
\Pi_{student\_salary}(\sigma_{student\_salary < 75000}(students))
\sigma_{student\_salary < 75000}(\Pi_{student\_salary}(students))
```

- Каждая операция реляционной алгебры может быть вычислена разными алгоритмами
- Связанное выражение, уточняющее детальную стратегию выполнения называется планом вычислений (evaluation-plan)
 - Используется индекс на *salary*, чтобы найти всех преподавателей с зп < 75000,
 - Или производится полный скан(обход) отношения и убирает инструкторов с зп ≥ 75000

Основные шаги обработки запросов: Оптимизация

- Оптимизация запросов: Из всех эквивалентных планов выполнения выбирается с меньшей стоимостью.
 - Стоимость вычисляется с использованием статистической информации из каталога базы данных.
 - Например, число кортежей в каждом отношении, размер кортежей и т.д.
- Далее мы изучим
 - Как измерить стоимость запроса
 - Алгоритмы для оценки операций реляционной алгебры
 - Как объединять алгоритмы для базовых операций в общее выражение
 - Как оптимизировать запросы и находить план выполнения с минимальной стоимостью

Меры стоимости запроса

- Многие факторы участвуют при оценке времени
 - *Доступ к диску, СРU*, и сетевые коммуникации
- Стоимость может быть вычислена на основе
 - времени ответа, т.е. общее время ответа на запросы
 - общее потребление ресурсов
- Будет рассматривать метрику по потреблению ресурсов
 - Время ответа сложнее вычислить, уменьшение потребления ресурсов хорошая метрика в общей (shared) БД
- Мы игнорируем стоимость CPU для простоты
 - Реальные системы используют стоимость СРU для оценки
 - Стоимость сети рассматривается для параллельных систем
- Опишем, как вычислить стоимость для каждой операции
 - Стоимость записи на диск игнорируем для простоты

Меры стоимости запроса

- Стоимость доступа на диск может быть рассчитана как:
 - Число поисков

- * среднее время поиска
- Число блоков чтения * среднее время чтения блока
- Число блоков записи * среднее время записи блока
- Для простоты учитываем **число трансфера блока** с диска и число поисков как меры стоимости
 - $t_{\scriptscriptstyle T}$ время для трансфера одного блока
 - Для простоты предполагаем, что стоимость записи соответствует стоимости чтения
 - $t_{\rm S}$ время для одного поиска
 - Стоимость для b трансферов блоков и S поисков $b * t_{\tau} + S * t_{s}$
- t_{S} и t_{T} зависят от того, где хранятся данные; с 4 КВ блоками:
 - HDD: $t_S = 4$ msec и $t_T = 0.1$ msec
 - SSD: : t_S = 20-90 microsec и t_T = 2-10 microsec для 4KB

Меры стоимости запроса

- Требуемые данные могут быть уже в буфере и, следовательно, не потребуется I/O
 - Но это сложно учитывать при оценке
- Часть алгоритмов может уменьшать дисковое Ю, если есть дополнительное место в буфере
 - Количество реально доступной памяти в буфере зависит от параллельных запросов и процессов ОС в момент выполнения
- Худший вариант предполагает, что изначально нет данных в буфере и только минимальное количество памяти может быть выделено для операции
 - Более оптимистичные сценарии обычно предполагают наличие места

Операция выборки

- Скан (обход) файла
- Алгоритм **А1** (**линейный поиск**). Обходит каждый блок файла и тестирует все записи на условие отбора.
 - Стоимость выполнения= b_r трансферов блока + 1 поиск
 - b_r определяет число блоков записей в отношении r
 - Если выборка по ключевом атрибуте, то можно остановиться при нахождении
 - Стоимость = $(b_r/2)$ трансферов блока + 1 поиск
 - Линейный поиск может применяться независимо от
 - Условия выборки
 - Сортировки записей в файле
 - Доступности индексов
- Замечание: для бинарного поиск обычно нет смысла, так как данные не хранятся последовательно
 - И бинарный поиск требует большее число поисков

Выборка при использовании индексов

- Обход индекса алгоритмы поиска, использующие индекс
 - Условие выборки должно содержать ключ поиска в индексе.
- **A2** (кластерный индекс, равенство по ключу). Вывод: одна запись, которая подходит по равенству по ключу
 - $Cmoumocmb = (h_i + 1) * (t_T + t_S)$
- А3 (кластерный индекс, равенство не по ключу). Вывод: несколько записей.
 - Записи должны быть на последовательных блоках
 - Пусть b = число блоков, содержащих совпадающие записи
 - Стоимость= $h_i^* (t_T + t_S) + t_S + t_T^* b$

Выборка при использовании индексов

- A4 (вторичный индекс, равенство (не) по ключу).
 - Возвращает одну запись, если ключ поиска уникален
 - Стоимость= $(h_i + 1) * (t_T + t_S)$
 - Возвращает несколько записей, если ключ поиска м.б. не уникален
 - Каждая из *п* совпадающих записей может быть в разных блоках
 - Стоимость = $(h_i + n) * (t_T + t_S)$
 - Может быть очень дорогой операцией

Выборки, включающие сравнения

- Можно разработать выборки формы $\sigma_{A \leq V}(r)$ или $\sigma_{A \geq V}(r)$ через
 - линейный обход файла,
 - использование индексов следующими способами
- A5 (кластерный индекс, сравнение). (Отношение отсортировано по A)
 - Для $\sigma_{A \geq V}(r)$ используется индекс для нахождения первого кортежа $\geq V$ и далее последовательный обход отношения
 - Для $\sigma_{A \le V}(r)$ просто последовательный обход отношения до момента, как кортеж> V;

Выборки, включающие сравнения

- Можно разработать выборки формы $\sigma_{A \leq V}(r)$ или $\sigma_{A \geq V}(r)$ через
 - линейный обход файла,
 - использование индексов следующими способами
- А6 (кластерный индекс, сравнение).
 - Для σ_{A ≥ V}(r) используется индекс для нахождения первой записи ≥ V и осуществлять последовательный поиск для нахождения указателя на записи
 - Для $\sigma_{A \le V}(r)$ обходить корневые страницы до условия > V
 - Если условие не соответствует порядку А, то может потребоваться одно чтение на запись

Реализация сложных выборок

- Конъюнкция: $\sigma_{\theta 1} \wedge {}_{\theta 2} \wedge \ldots {}_{\theta n}(r)$
- A7 (конъюнктивная выборка с использованием одиночного индекса).
 - Все условия по индексу проверяем
 - Остальные проверки в буфере памяти
- A8 (конъктивная выборка с использованием сложного индекса.
 - Используется подходящий сложный составной индекс.
- A9 (конъюнктивная выборка с пересечением идентификаторов).
 - Пересекаем указатели, подходящие для индексов
 - Остальные проверки в памяти

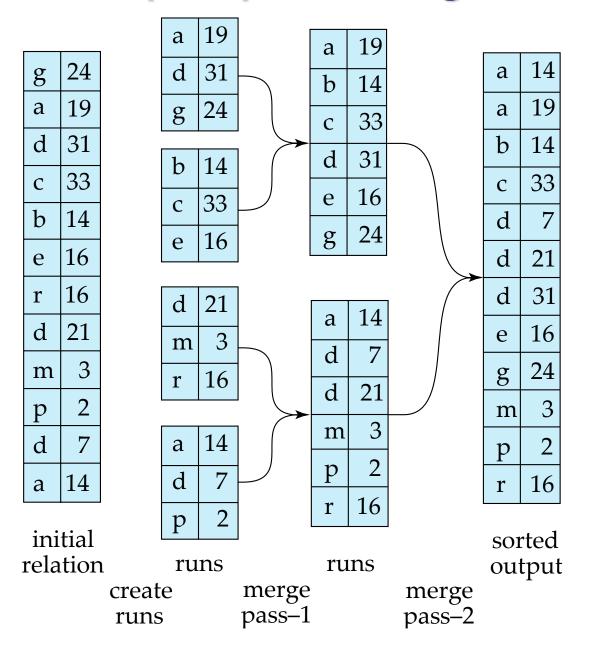
Алгоритмы для сложных выборок

- Дизъюнкция: $\sigma_{\theta 1} \vee_{\theta 2} \vee \ldots_{\theta n} (r)$.
- А10 (дизъюнктивная выборка по объединению идентификаторов).
 - Применима, если все условия имеют индексы
 - В другом случае линейный поиск
- Отрицание: σ_{¬θ}(r)
 - Линейный поиск по файлу
 - Если не много записей $\neg \theta$, и индекс применим по θ
 - Найти подходящие записи по индексу

Сортировка

- Можно построить индекс по отношению, и использовать индекс для чтения в том же порядке. Для каждого кортежа может потребоваться только одно чтение.
- Для отношений, помещающихся в памяти, можно использовать стандартные сортировки, например quicksort. Для не помещающихся external sort-merge.

Пример: Sort-Merge



Стоимость сортировки

Пусть b_r - число блоков в отношение r. Первая стадия — чтение каждого блока отношения и его перезапись - $2b_r$. Изначальное число пробегов - $\frac{b_r}{M}$ Для эффективного слияния требуется b_b буферных блоков для каждого входа пробега и его выхода.

Поэтому $\frac{M}{b_b} - 1$ пробегов сливаются в каждый момент слияния.

Следовательно, общая величина для слияний - $\log_{\frac{M}{b_{h}-1}}(\frac{b_{r}}{M})$

В каждом таком слиянии происходит одно чтение каждого блока и одна запись каждого блока (кроме последнего, запись не нужна)

В итоге общее число переносов будет

$$b_r(2[\log_{\frac{M}{b_b}-1}\left(\frac{b_r}{M}\right)+1)$$

Стоимость сортировки

Для подсчета числа поисков используется следующее предположение Каждому слиянию потребуется $\frac{b_r}{b_b}$ поисков, аналогично для записи, кроме последнего слияния В итоге получаем

$$\frac{2b_r}{M} + (b_r/b_b) (2[\log_{\frac{M}{b_b}-1} \left(\frac{b_r}{M}\right) - 1)$$

Соединения

Базовый алгоритм для соединения $r\bowtie_{\theta}s$:

```
for каждого кортежа t_r в r: for каждого кортежа t_s в s: сравнить пару (t_r,t_s) на \theta если true, то добавить t_r \cdot t_s в результат
```

R – внешнее отношение

S – внутреннее отношение

Вложенные циклы (оценка)

Для применения данного алгоритма не требуются никакие дополнительные структуры.

Общее число пар - $n_r \cdot n_s$,

где n — число кортежей

В худшем случае, если буфер может содержать только 1 блок каждого отношения, то потребуется $n_r * b_s + b_r$ переносов блоков. В лучшем, $b_s + b_r$

Если одно из отношений помещается в память, то его лучше использовать как внутренне отношение, так как в таком случае чтение будет только одно. В таком случае будет $b_s + b_r$ переносов и всего 2 поиска.

Вложенные циклы (блочный алгоритм)

В случае, когда буфер слишком мал, чтобы содержать полностью отношение, можно ориентироваться не на кортежи, а на блоки.

Алгоритм

```
for каждый блок B_r отношения r: for каждый блок B_s отношения s: for каждый кортеж t_r в B_r: for каждый блок t_s в B_s: проверить пару (t_r, t_s) на \theta если true, то добавить (t_r, t_s) в результат
```

Оценка (блочный вариант)

В худшем случае будет $b_r * b_s + b_r$ переносов. Каждый обход внутреннего отношения — 1 поиск, и поиск внешнего отношения — 1 поиск на блок. Поэтому всего $2*b_r$ поисков. Более эффективно использовать меньшее отношение как внешнее отношение, если они оба не помещаются в память.

Блочный вариант (оптимизация)

В блочном варианте для внешнего отношения можно использовать наибольший объем, который есть в памяти.

Если в памяти М блоков, то М-2 блоков считывается для внешнего отношения.

Уменьшается количество поисков с b_r до $\frac{b_r}{M-2}$.

Общее число переносов блоков = $\frac{b_r}{M-2}*b_s+b_r$

Общее число поисков блоков = $2 * \frac{b_r}{M-2}$

Вложенные циклы (индекс)

Если задан индекс для внутреннего отношения, то работа с таблицей может быть заменена на работу с индексом. Проверка соответствия соединения проверяется на уровне индекса, а не таблицы.

Стоимость $b_r(t_T + t_S) + n_r * c$

с – стоимость работы с индексом и нахождения всех кортежей s для одного кортежа r

Соединение слиянием (Merge-Join)

Предполагается, что оба отношения отсортированные по пересечению их атрибутов соединения.

```
pr := адрес первого кортежа r
рѕ := адрес первого кортежа ѕ
while (ps != null and pr != null)
 t_s \coloneqq кортеж указателя ps
 S_s := \{t_s\}
 ps \coloneqq следующий кортеж а s
 done := false
 while (not done and ps! = null)
  \mathsf{t}_s' \coloneqq кортеж указателя \mathit{ps}
  if (t'_s[JoinAttrs] = t_s[JoinAttrs]
    S_s := S_s \cup \{t'_s\}
    ps \coloneqq следующий кортеж в s
  else
     done := true
 t_r \coloneqq кортеж указателя pr
 while (pr! = null \text{ and } t_r[JoinAttr] < t_s[JoinAttrs])
  pr ≔ следующий кортеж в r
  t_r \coloneqq  кортеж указателя pr
 while (pr! = null \text{ and } t_r[JoinAttr] = t_s[JoinAttrs])
  рг ≔ следующий кортеж в г
  for each t_s B S_s
    Добавить t_{\scriptscriptstyle S}\bowtie t_{\scriptscriptstyle S} в результат.
  рг ≔ следующий кортеж в г
  t_r \coloneqq кортеж указателя pr
```

Merge Join

Каждый блок прочитан будет только однажды при условии, что все кортежи помещаются в памяти

Стоимость переноса =
$$b_r + b_S$$

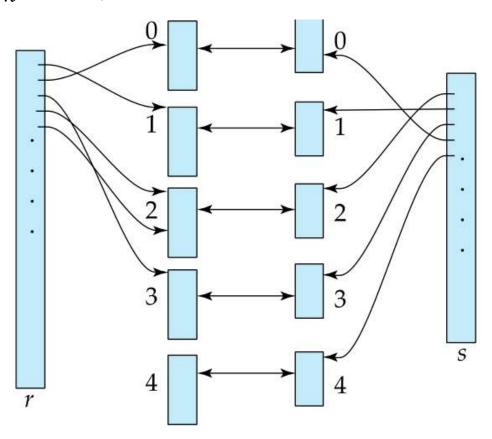
Стоимость поиска =
$$\frac{b_r}{b_b} + \frac{b_s}{b_b}$$

Гибридное соединение слиянием. Если одно из отношений отсортировано, а во втором есть вторичный индекс В+ дерева по атрибуту соединения

Hash Join

h – функция отображения JoinAttrs на пространство секций

$$r_0, r_1, \dots, r_n$$
 — секции r s_0, s_1, \dots, s_n — секции s



Hash Join алгоритм

- 1. Разбить отношение s на секции
- 2. Разбить отношение г на секции
- 3. Для каждого і:
 - 1. Загрузить s_i в память и построить хеш-индекс в памяти
 - 2. Считывать кортежи в r_i по одному. Для каждого кортежа t_r найти совпадающий кортеж t_s в s. Вывести конкатенацию

В случае, если число секций больше числа блоков в памяти, то появляется рекурсивное партиционирование.

Hash Join Стоимость

Требуется $3(b_r+b_s)+4n_h$ переносов Требуется $2\left(\frac{b_r}{b_b}+\frac{b_s}{b_b}\right)$ поисков

В случае рекурсивного партиционирования потребуются дополнительные расходы



Обработка запросов (продолжение)

Другие операции (убрать дубликаты)

- Забор от дубликатов может быть сделано с использованием сортировки. Дубликаты находятся последовательно при сортировки, что позволит их быстро удалить
- Если выполняется внешняя сортировка слиянием, то дубликаты можно удалить на стадиях внутренних слияний
- Также можно сделать удаление дубликатов через хеширование.
 В момент построения внутреннего хеш-индекса кортеж добавляется только, если его до этого не было.

Другие операции (Проекция)

 Проекция выполняется применением проекции для каждого кортежа, а затем отбросом дубликатов по необходимости (если в списке есть ключ отношения, то выполнять отброс дубликатов не требуется).

Другие операции (Операции с множествами)

 При операции с множествами (UNION, INTERSECT, EXCEPT), можно сначала отсортировать оба множества, а затем применять совместный обход двух отношений.

Другие операции (Операции с множествами)

- Хеширование предоставляет другой способ реализации операций со множествами. Первый шаг в любом случае это секционирование двух отношений с использованием одной и той же хеш-функции, что приводит к созданию секций r₀, r₁, ..., r_n и s₀, s₁, ..., s_n
- $r \cup s$. Для каждой партиции i = 0, 1, ..., n:
 - Построить хеш индекс по r_i
 - Для каждого кортежа в s_i , добавить его в хеш-индекс, если его нет в хеш-индексе
 - Добавить кортежи из хеш-индекса в результат

Другие операции (Операции с множествами)

- Хеширование предоставляет другой способ реализации операций со множествами. Первый шаг в любом случае это секционирование двух отношений с использованием одной и той же хеш-функции, что приводит к созданию секций r₀, r₁, ..., r_n и s₀, s₁, ..., s_n
- $r \cap s$. Для каждой партиции i = 0, 1, ..., n:
 - Построить хеш индекс по r_i
 - Для каждого кортежа в s_i , добавить его в результат, если он есть в хеш-индексе

Другие операции (Операции с множествами)

- Хеширование предоставляет другой способ реализации операций со множествами. Первый шаг в любом случае это секционирование двух отношений с использованием одной и той же хеш-функции, что приводит к созданию секций r₀, r₁, ..., r_n и s₀, s₁, ..., s_n
- r-s. Для каждой партиции i=0,1,...,n:
 - Построить хеш индекс по r_i
 - Для каждого кортежа в s_i , удалить их хеш-индекса, если он есть в хеш-индексе
 - Добавить все кортежи из хеш-индекса в результат

Другие операции (Внешние соединения)

- Для вычисления r м можно вычислить сначала r м $_{\theta}$ s и сохранит данный результат во временное отношение q. Затем вычислить $r \Pi_R(q)$ для получения кортежей из r, которые не соединились с s. После этого дополнить кортежи null значения в требуемых полях
- Правое и полное внешнее соединения работают аналогично

Другие операции (Внешние соединения)

- Можно доработать алгоритмы. Можно дополнить алгоритм вложенных циклов правилом дополнения кортежа null – значениями в случае не нахождения соединения во внутренним цикле.
- Соединение слиянием может быть расширено: Если не найдено совпадение с другим отношением, то осуществляется дополнение кортежей с помощью null.

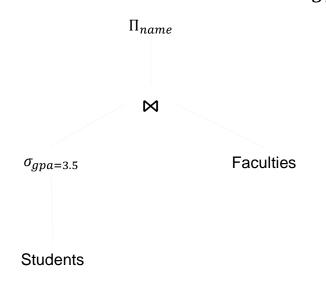
Другие операции (Агрегация)

- Агрегация может быть реализована с использованием сортировки или хешированием. Операция производится по полям группировки, а затем агрегация применяется для каждой группы.
- Часть имплементаций предполагает вычисление агрегатов «на лету»

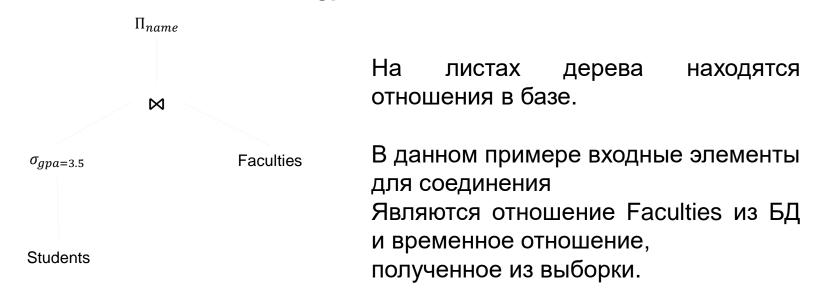
Вычисление выражений

- Для вычисления выражений, содержащих несколько реляционных операций, существует несколько вариантов вычисления.
- Если каждая операция вычисляется отдельно и результатом такого шага является временное отношение, то такая ситуация называется материализацией.
- Альтернативным способом является организация конвейера (pipeline) выполнения параллельных операций

Операцию реляционной алгебры можно представить в виде дерева операций: $\Pi_{name}(\sigma_{gpa=3.5}(Students)) \bowtie Faculties)$



Операцию реляционной алгебры можно представить в виде дерева операций: $\Pi_{name}(\sigma_{gpa=3.5}(Students)) \bowtie Faculties)$



Материализованное вычисление представляет собой последовательность вычислений, в которой создается каждая промежуточная операция (материализуется) и используется для вычислений дальнейших шагов.

Для вычисления стоимости требуется добавить стоимость всех операций и стоимость записи временных результатов на диск.

Материализованное вычисление представляет собой последовательность вычислений, в которой создается каждая промежуточная операция (материализуется) и используется для вычислений дальнейших шагов.

Для вычисления стоимости требуется добавить стоимость всех операций и стоимость записи временных результатов на диск.

Одним из вариантов оптимизаций является двойная буферизация (один из буферов осуществляет вычисление, другой – запись)

Конвейер

- $\blacksquare \quad \Pi_{a,b}(r\bowtie s)$
- Уменьшение стоимости чтения и записи временных отношений
- Довольно быстрый отклик в передаче результатов запроса, если план запроса позволяет полноценный конвейер.

Реализация конвейера

- Конвейер может быть 2 типов:
- Demand-driven (Ленивое вычисление). Результат запроса операций низкого уровня не передается автоматически на более высокий уровень. Он будет передан, когда будет осуществлен запрос более высокого уровня.

Реализация конвейера

- Конвейер может быть 2 типов:
- Producer-driven (Жадное вычисление). Операции не ждут запрос для вычисления кортежей. Каждая операция в producer-driven конвейере моделируется как отдельный процесс или поток в системе, которая на вход принимает поток кортежей и на выходе также поток кортежей.

Реализация конвейера вычислений

- Каждая операция в ленивом конвейере может быть разработана как итератор, который предоставляет следующие функции: open(), next(), close()
- После вызова open(), каждое обращение к next() возвращает следующий кортеж на выход операции.
- Функция close() сообщает итератору, что больше кортежей не требуется
- Итератор хранит состояние вычисления между вызовами.

Реализация конвейера вычислений

- Конвейеры с жадным вычислением реализованы другим образом
- Для каждой смежной пары операций в конвейере, система создает буфер для фиксации кортежей, передающиеся с одной операции на другую.
- Процессы (или потоки) разных операций работаю параллельно.
- Каждая операция внизу кортежа последовательно вычисляет кортежи для вывода, и передает его в буфер вывода, до момента переполнения буфера.

Реализация конвейера вычислений

- Как только операция использует кортеж из входного буфера, он удаляется из буфера.
- Если буфер вывода полный, то операция ожидает забор данных из буфера более высокоуровневой операцией.
- Существует возможность распараллеливания операций внутри конвейера в случае многопроцессорных систем.

конвейеров

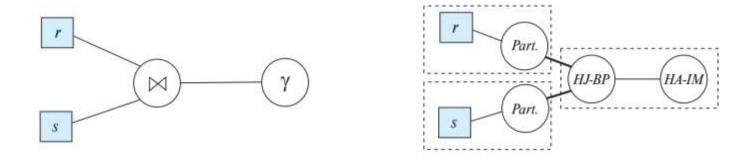
- Планы запросов могут указывать, для каких вершин выполняется конвейеризация (конвейерные вершины). Другие вершины называются блокирующими вершинами (материализованными).
- Множество всех соединенных конвейерных вершин вычисляется параллельно.
- План запроса может быть разделен на поддеревья, вершины между которым являются блокирующими.
- Каждое такое поддерево называется стадией конвейера.

конвейеров

- Каждые операции, такие как сортировка, по существу являются блокирующими, так как они не могут выдавать результат до того, как все кортежи были забраны из входных отношений.
- При этом блокирующие операции могут выдавать выходные результат по мере их появления.
- Пример. Сортировка внешним слиянием. 1) Формирование шагов
 2) Слияние. Шаг 1 может быть применен по мере появления кортежей во входном буфере, и поэтому может быть применена конвейеризация. Шаг 2 может посылать выходные результаты по мере их появления, но при этом для начала требуется полное завершение шага 1.

- Другие операции (например, соединение) могут быть не полностью не блокирующими, но при этом специфическое вычисление алгоритмов может приводить к блокировке.
- Например, алгоритм вложенных циклов с использованием индекса может выдавать результирующие кортежи, как только кортеж получен для внешнего отношения. Поэтому данная часть является конвейерной.
- При этом, так как индекс должен быть полностью сконструирован, то правая часть является блокирующей.

 Алгоритм хеш соединения является блокирующей операцией для обоих входов, так как требуется полное получение всех кортежей и секционирование отношения.



- Для каждой материализованной вершины должна быть возможность добавить стоимость записи данных на диск, и стоимость чтения данных на диск.
- Когда материализованная вершина находится между элементами одного оператора (например стадии пробега и слияния), тогда стоимость материализации заранее была добавлена в оценку стоимости и не требует дополнительной оценки.

- В части приложений может быть алгоритм соединения, который является конвейером. Например, если оба входа отсортированы по атрибутам и каждое условие соединения является эквисоединением, может быть применен алгоритм merge-join.
- Существует альтернатива двойного-конвейерного соединения.
 Алгоритм предполагает, что входные кортежи являются конвейерными.

- Конвейеры для потоковых данных
- Данные, поступающие на непрерывной основе (например IOT), представляют собой потоки данных.
- Запросы могут быть реализованы на потоковых данных по мере их поступления. Такие запросы называются непрерывными.
- Для таких запросов часто выделяют понятие окна. Результатом вычисления в окне может быть выдан в результат, если известно, что новых данных поступать уже не будет.

Обработка запросов в памяти

- Все предыдущие алгоритмы были связаны с минимизацией в I/O
- Для минимизации работы в памяти часто используется оптимизации для кеш уровня.

Алгоритмы оптимизации в кеше

- Разность в скорости между кешем или памяти, и тот факт, что данные передаются между памятью и кешем в элементах под названием кеш-линия (обычно около 64 байт).
- Работа с CPU кешем контролируется алгоритмами, которые сделаны на уровне hardware.
- Для сортировки отношения в памяти используется алгоритм слияния с выбором пробега, который попадает в кеш. Слияние эффективно работает с кешем, так как читени происходит на уровне слов.

Алгоритмы оптимизации в кеше

- Компиляция запросов
- Традиционно обработка запроса представляло собой интерпретатор, который вычислял план запроса. Возникает довольно большая проблема с накладными расходами для работы с метаданными или пользовательскими функциями.
- Современные СУБД компилируют планы запросов в машинный код или байт-код. Например, компилятор может заранее вычислить смещение в странице.